Исследование по рекомендательным системам

RL для последовательных рекомендаций

Задание 2. Yambda, GPT-2, reward model и REINFORCE

24 октября 2026 года

Содержание

Краткое содержание **1**

1 Данные и доступная информация **1**

2 GPT-2 и честное сравнение **2**

3 Reward model: качество на logged actions **3**

4 RL: функция цели и обновление **4**

5 Релевантность и компромисс с наградой **6**

6 Как меняется поведение и есть ли коллапс **7**

7 Пять шагов: рекомендация не равна действию **9**

7.1 Ожидаемая награда пяти stochastic шагов 11

8 Долгосрочные цели: что доступно офлайн **11**

9 Стоимость, надёжность и воспроизведение **12**

10 Связь со статьями и ограничения **13**

11 Основные выводы **14**

Дополнительные таблицы **14**

Краткое содержание

Второе задание. Реальный эксперимент на Yambda: GPT-2 по ID треков, предиктор доли дослушивания и on-policy REINFORCE. Все числа ниже получены запуском приложенного кода; положительный эффект RL не предполагался заранее.

Первичное сравнение: balanced RL против continued-CE. NDCG@10: 0.00686 → 0.00679. Δ и 95% ДИ: -0.00008 [-0.00107; +0.00084]. Интервал не подтверждает рост релевантности.

Изменение ожидаемого completion основной RM: +0.00297 [+0.00264; +0.00328]; аудиторской RM: +0.00158 [+0.00136; +0.00180]. Обе величины — предсказания моделей на предлагаемых действиях, а не наблюдаемый пользовательский эффект.

По заранее заданному правилу confirmation выбран Balanced, β=.10. Это решение принято до вычисления финальных test metrics. Первичное сравнение от выбора не меняется.

Масштаб: 4,889,035 записей, 1000 случайных слушателей, словарь 16 384 трека, три seed обучения. Семь вариантов дообучения, frozen SFT и два простых контроля. CPU, без предобученных текстовых весов.

Отчёт отвечает на пять вопросов: изменение поведения; сохранение релевантности и коллапс; долгосрочные цели; ошибки перехода при пяти шагах; компромисс между reward и точностью. Код и команды находятся в README.md. Дата: 24 октября 2026.

1 Данные и доступная информация

Источник — yandex/yambda, `sequential/50m/listens.parquet`, закреплённая revision `dd6f3a19eef5866e346c3270e098baa641a44948`. Равномерно выбраны 1000 из 9238 пользователей, имеющих строку listens, seed 314. Дополнительного фильтра по активности нет. Сохранены все предоставленные listening events этих пользователей; другие типы действий не скачивались.

Медиана истории 2752 событий; минимум 12. Органическая доля 52.1%. Повторы и 23,038 точных дубликатов сохранены. Они могут отражать особенности источника; для reward label одинаковые user/time/item объединяются средним.

Время — секунды от начала наблюдения с округлением до 5 секунд. 981,971 записей имеют уже встречавшийся user/timestamp. Их порядок неизвестен. Префикс всегда timestamp $<$ t. В прошлых группах используется техническая сортировка item ID. Все цели неоднозначных timestamp-групп исключены из LM loss, но остаются в истории и групповых оценочных целях.

Общая временная граница одинакова для всех пользователей. Три последние недели — validation, confirmation и test. Во время оценки доступна реально наблюдённая история до текущего запроса, включая более ранние события этой недели; веса фиксированы. Это prequential-протокол, а не замороженная история на начало недели.

Словарь — top-16 384 по частоте только в train. Остальные ID сохраняются как UNK; PAD/BOS/UNK запрещены среди рекомендаций. Длительность — train median по треку, предполагается доступным стабильным метаданным. Полные истории сохранены, GPT видит до 64 токенов в базовом запросе.

Vocabulary, embeddings и глобальная популярность — фиксированные параметры/статистики, выученные ко времени train_end. Более ранние train-префиксы преобразуются ими ретроспективно; не утверждается их доступность в исторический момент каждого train row. В validation/test они уже известны до начала периода. RL обучается на прошлых префиксах с каталогом train_end, а не воспроизводит исторические deployment policies; для такой задачи потребовался бы release-time каталог.

Таблица 1: Данные и доступная информация

Часть	**Начало, включено**	**Конец, исключён**	**Запросы**	**Покрытие целей**
train	0	24185590	12000	93.2%
validation	24185590	24790390	512	54.9%
confirmation	24790390	25395190	1024	51.8%
test	25395190	25999990	2048	52.7%

2 GPT-2 и честное сравнение

GPT2LMHeadModel обучен с нуля: 2 causal decoder layers, 4 attention heads, width 128 (выбор из 96/128 по validation NDCG@10), tied input/output embeddings. Токен — ID трека. Dropout .1 при SFT; AdamW lr .001, batch 32, до 8 эпох, patience 2, clip gradient norm 1.

В SFT выбраны 30 000 перекрывающихся окон (stride 32) из train. Всего 645,171 допустимых target positions на эпоху с учётом повторов в окнах. Loss — next-token CE только для известных, неорганических и однозначных по времени целей. Органические события и UNK входят в контекст. У коротких историй BOS и левый padding; loss на padding отсутствует.

SFT checkpoint выбирается по validation. Для выбранной архитектуры обучены отдельные seed 42/43/44. Все варианты дообучения внутри seed стартуют с одной и той же сохранённой SFT. Continued-CE получает те же 300 updates и те же начальные префиксы. Его set loss

$$\mathcal{L}_{\mathrm{CE}} = -\log \sum_{i \in P_t} \pi_\theta(i \mid s_t), \tag{1}$$

где P_t — известные неорганические цели timestamp-группы; при одной цели это обычный CE. Тот же loss используется в balanced auxiliary term. Это контроль дополнительного обучения; число FLOPs, actions и затраты времени не приравниваются.

Оценочный запрос — user/timestamp с неорганическими событиями; положительные объекты — уникальные неорганические item ID этой группы. Ранжирование точное по всем 16 384 доступным трекам, без sampled negatives. Повторы разрешены: в музыке знакомый трек может быть релевантен. Поэтому repeat — диагностика, а не автоматически ошибка.

Оценочные запросы равномерно сэмплируются без возвращения из всех подходящих timestamp-групп: 512/1024/2048 на validation/confirmation/test. Для 12 000 RL/continued-CE train states дополнительно требуется хотя бы одна known positive, чтобы определить CE loss. Во временных holdout такого фильтра нет; полностью OOV-запросы сохраняются. Для всех методов используются одни и те же cached queries.

В test 2048 запросов у 434 пользователей; 931 запросов полностью вне словаря. Общие Recall/NDCG/MAP@5/10/20 включают OOV-цели с нулевым вкладом. Conditional-метрики делят только на известные цели и исключают полностью OOV-запросы. Это разные estimands.

Query-macro NDCG использует бинарную релевантность, ideal DCG по min(K, число всех целей); MAP — сумму precision на hit-позициях, делённую на min(K, число целей). Для conditional вариантов знаменатели пересчитываются по known targets. Дополнительные контроли: train popularity и $0.9 \cdot$ частота в текущем контексте $+ 0.1 \cdot$ train popularity.

Позитивом считается любой logged неорганический listen, включая малый completion. Поэтому ranking metrics измеряют matching исторических действий logging policy, а не экспертную или причинную удовлетворённость. Снижение NDCG само по себе не доказывает ухудшение

пользовательского опыта; концентрация и другие диагностики помогают понять характер изменения.

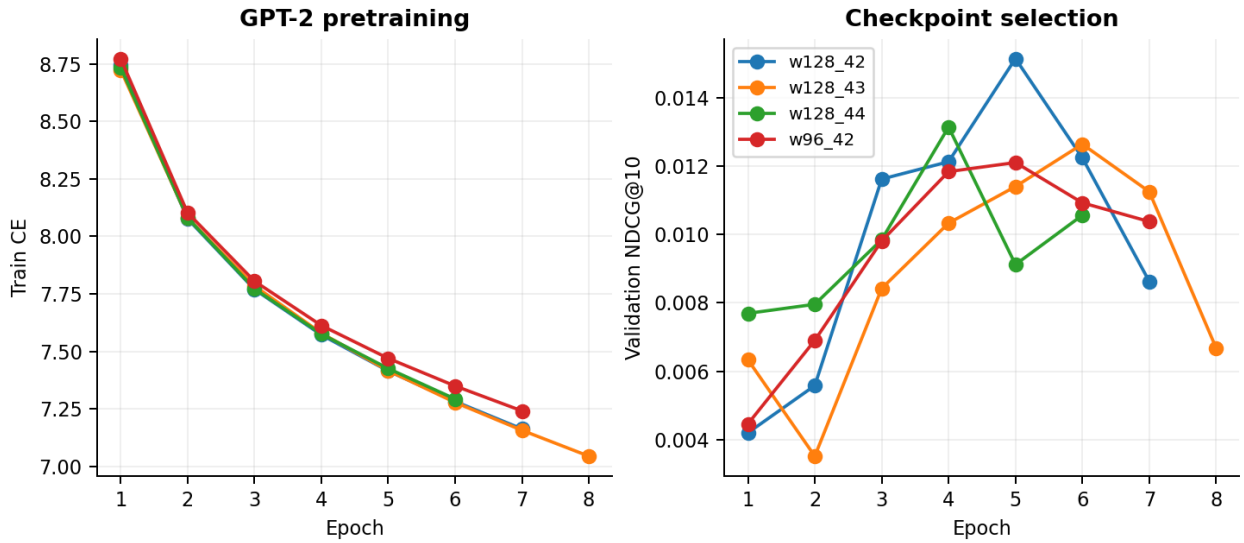


Рис. 1: Обучение и выбор SFT checkpoint; test не используется для остановки.

3 Reward model: качество на logged actions

Основная цель — clip(played_ratio_pct/100, 0, 1). В источнике ratio >100 означает повторное воспроизведение; clipping — выбранная функция полезности, а не исправление ошибочных данных. Входы: ID кандидата и последнего трека, train duration/popularity, число прошлых событий, повторы, статистики последних ID, PCA-16 embeddings и сходство кандидата с профилем.

Текущий played_ratio, completion и будущее поведение отсутствуют во входах. Embeddings фиксированы из SFT seed 42. Completion — ансамбль трёх CatBoost RMSE, depth 8, максимум 350 trees, lr .06; depth 6/8 и early stopping 40 выбираются только на validation. Дополнительные два члена используют bootstrap weights по пользователям.

Отклики оптимизируемой RM обучены на 60,820 train rows одной случайной половины пользователей; ExtraTrees-аудитор — на 59,180 rows другой половины. Разделены response labels, но обе модели используют общее фиксированное представление из SFT. Аудитор не участвует в RL loss или выборе checkpoint. Это проверка чувствительности к surrogate, а не независимая истина.

Для каждого reward row и completion, и 48-часовой return label должны полностью наблюдаться внутри своего split; учитывается консервативное время завершения текущего трека. Reward test содержит 20 000 реальных logged действий с известными item ID. Это условная предиктивная оценка на logging distribution; на новых действиях после RL калибровка не гарантирована.

Обучение RM условно на наличии записи listens. Она не оценивает вероятность принять рекомендацию при показе: в выбранном файле нет непрослушанных показов. Поэтому expected completion политики предполагает, что отклик на предлагаемый объект сопоставим с откликом на logged listen; эту selection/transition гипотезу офлайн-метрики не проверяют.

Top-decile bias — среднее prediction минус outcome среди верхнего дециля данного предиктора. Для константного baseline это все строки из-за ties. Полные calibration tables, predicted/observed

values и результаты return proxy сохранены отдельно.

Таблица 2: Reward model: качество на logged actions

Completion model	MAE	RMSE	R^2	Top-decile bias
optimized_rm	0.3338	0.3860	0.1357	-0.0041
audit_rm	0.3425	0.3868	0.1321	-0.0567
global_mean	0.3920	0.4183	-0.0153	-0.0513
train_item_mean	0.3789	0.4130	0.0103	-0.0325

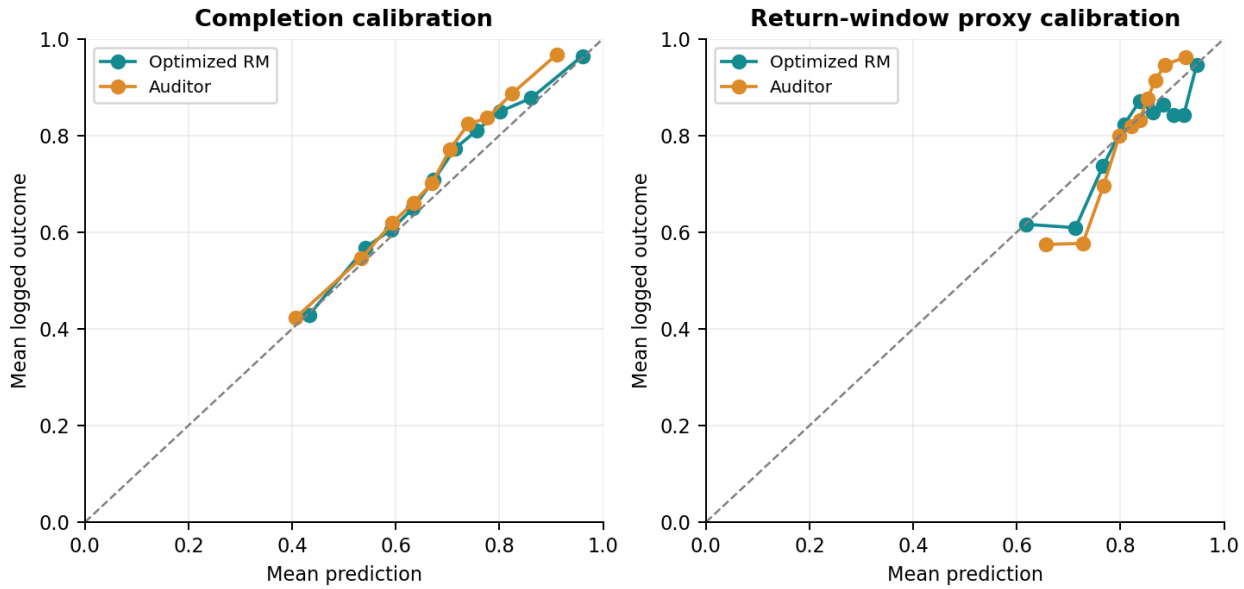


Рис. 2: Калибровка на реально наблюдавшихся test actions. Она не устанавливает counterfactual calibration.

4 RL: функция цели и обновление

Используется on-policy grouped REINFORCE с baseline из трёх других траекторий того же реального префикса. На update выбираются 16 train states, по 4 траектории, по 5 действий. Полный softmax по словарю, temperature 1, gamma .9, AdamW lr .0001, 300 updates, clip norm 1. Для каждого RL run сэмплируются 96 000 действий.

На шаге t используется shaped reward с замороженной reference-политикой SFT:

$$\tilde{r}_t^{(k)} = r_t^{(k)} - \beta \log \frac{\pi_\theta(a_t^{(k)} \mid s_t^{(k)})}{\pi_{\mathrm{SFT}}(a_t^{(k)} \mid s_t^{(k)})}, \tag{2}$$

$$G_t^{(k)} = \sum_{j=t}^{H-1} \gamma^{j-t} \tilde{r}_j^{(k)}, \tag{3}$$

$$A_t^{(k)} = G_t^{(k)} - \frac{1}{K-1} \sum_{\ell \neq k} G_t^{(\ell)}, \qquad K = 4, \quad H = 5. \tag{4}$$

Остальные три независимо сэмплированные траектории того же начального префикса задают

leave-one-out baseline. Функция потерь имеет вид

$$\mathcal{L}_{\mathrm{RL}}(\theta) = -\frac{\mathbb{E}_k\left[\sum_{t=0}^{H-1}\gamma^t \ \mathrm{stopgrad}(A_t^{(k)})\log \pi_\theta(a_t^{(k)} \mid s_t^{(k)})\right]}{\sum_{t=0}^{H-1}\gamma^t}. \tag{5}$$

Усреднение также выполняется по начальным префиксам batch. Sampling и gradient replay используют одну текущую политику без dropout; после update rollout больше не используется. При continued-CE dropout также выключен, gradient update остаётся включённым.

При append выбранный ID добавляется в контекст как предположение surrogate среды. В frozen bandit состояние не меняется, а baseline строится по немедленным rewards, поскольку действия не имеют будущих последствий. Это matched по числу actions/updates контроль контекстных переходов, а не ещё одна реалистичная модель пользователя.

Completion сравнивается при $\beta \in \{0, 0.05, 0.20\}$. Для других целей:

$$r_{\mathrm{seconds}} = \frac{\min(d, 600)\, c}{300}, \tag{6}$$

$$r_{\mathrm{balanced}} = 0.7c + 0.2q + 0.1n - 0.25 I_{\mathrm{recent}} - 0.1\sigma_{\mathrm{RM}}, \tag{7}$$

$$n = 1 - \frac{\log(1 + \mathrm{train_count})}{\log(1 + \mathrm{max_count})}. \tag{8}$$

Здесь c — predicted completion, q — return proxy, d — длительность трека в секундах, n — novelty, I_{recent} — повтор в последних 64 токенах, а σ_{RM} — расхождение bootstrap reward models. Для balanced добавлен $0.05\mathcal{L}_{\mathrm{CE}}$ по реальным целям. Коэффициенты заданы до RL и не подбирались по test.

Checkpoints 100/200/300: максимум собственной ожидаемой validation utility. Balanced сначала требует $\geq$95% SFT validation NDCG, иначе берёт лучший NDCG и отмечает провал ограничения. Continued-CE выбирается по validation NDCG. Ожидаемые rewards оцениваются 32 Monte Carlo действиями на запрос с общими uniforms для всех политик; ranking считается точно.

Frozen SFT задаёт KL reference, а RM и embeddings не обновляются во время RL. У всех вариантов идентичный каталог и исходные checkpoints. В конфигурации сохранены seeds, horizons, коэффициенты и правило выбора.

Таблица 3: RL: функция цели и обновление

Вариант	**Шаги seed 42/43/44**	**Validation NDCG**	**SFT floor**
Continued CE	100 / 200 / 100	0.01479	не задан
Completion, β=0	300 / 300 / 300	0.00025	не задан
Completion, β=.05	300 / 300 / 300	0.01026	не задан
Completion, β=.20	300 / 300 / 300	0.01325	не задан
Секунды, β=.10	300 / 300 / 300	0.01227	не задан
Balanced, β=.10	300 / 300 / 200	0.01377	3/3
Bandit, β=.05	300 / 300 / 300	0.01147	не задан

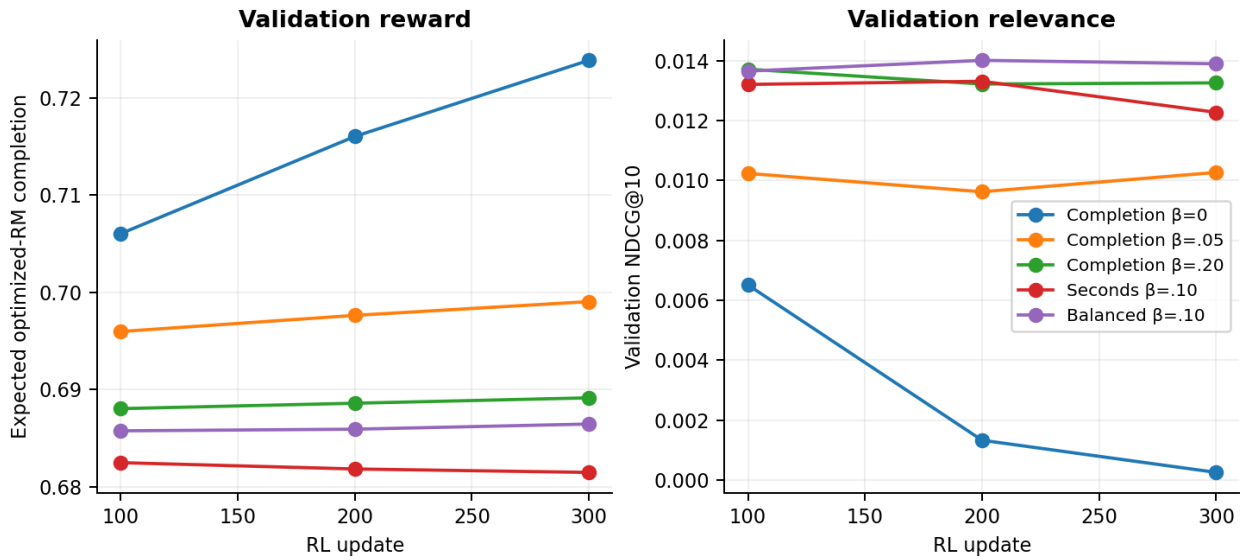


Рис. 3: Validation checkpoints: награда и релевантность могут меняться в разных направлениях. Floor относится только к balanced.

5 Релевантность и компромисс с наградой

В таблице — среднее метрик трёх отдельных моделей. Вероятности не ансамблируются. Reward означает ожидаемый completion оптимизируемой RM при sample temperature 1; Audit — то же по аудиторской RM. Эти scores относятся к предлагаемым действиям, а NDCG — к фактическим действиям в логах.

NDCG mean ± SD по seed: SFT 0.00688 ± 0.00071; continued-CE 0.00686 ± 0.00056; balanced 0.00679 ± 0.00120. Полные отдельные seed и все K доступны в summary.json.

Простые контроли: popularity NDCG 0.00169, recent-frequency 0.00490; SFT 0.00688. Completion с β=.20 даёт средние NDCG 0.00706 и RM 0.6981; frozen-bandit — 0.00725 и 0.7058. Эти дополнительные test точки описательны и не меняют решение на confirmation.

Первичное balanced − continued-CE: NDCG -0.00008 [-0.00107; +0.00084], reward +0.00297 [+0.00264; +0.00328], audit reward +0.00158 [+0.00136; +0.00180]. Bootstrap парный по пользователям, 2000 повторов; сначала усредняются per-query метрики трёх matched seed. Все запросы resampled пользователя идут вместе. Интервалы условны на этих трёх обучениях и общих MC draws; не учитывают всю вариативность train samples/seed.

Confirmation правило: порог NDCG 0.00568; прошли Секунды, β=.10, Balanced, β=.10. Выбран Balanced, β=.10, test NDCG 0.00679, reward 0.6953. Описание этого результата не заменяет первичное сравнение.

Эмпирический Pareto frontier вычислен по средним test NDCG и optimizer reward. Это описательный анализ, не новое правило выбора модели. Дополнительные интервалы и сравнения исследовательские, без поправки на множественные проверки; отсутствие значимости не доказывает эквивалентность и порог 95% не является статистическим non-inferiority тестом.

Reward functions имеют разные шкалы: completion в [0,1], seconds после деления на 300 может достигать 2. Поэтому одинаковый β между разными functions не означает одинаковую силу ограничения относительно reward. Balanced меняет несколько компонентов и добавляет CE одновременно; этот эксперимент не выделяет причинный вклад каждой составляющей по отдельности. Для этого нужен отдельный factorial/ablation протокол.

Таблица 4: Релевантность и компромисс с наградой

Модель	NDCG@10	Recall@10	MAP@10	RM	Audit
Популярность	0.00169	0.00309	0.00095	0.6471	0.6487
Частота в контексте	0.00490	0.00842	0.00334	0.6944	0.6816
SFT GPT-2	0.00688	0.01542	0.00412	0.6925	0.6780
Continued CE	0.00686	0.01546	0.00408	0.6923	0.6778
Completion, β=0	0.00157	0.00326	0.00107	0.7346	0.6940
Completion, β=.05	0.00669	0.01316	0.00451	0.7089	0.6867
Completion, β=.20	0.00706	0.01494	0.00442	0.6981	0.6809
Секунды, β=.10	0.00553	0.01167	0.00344	0.6906	0.6763
Balanced, β=.10	0.00679	0.01505	0.00406	0.6953	0.6794
Bandit, β=.05	0.00725	0.01544	0.00453	0.7058	0.6851

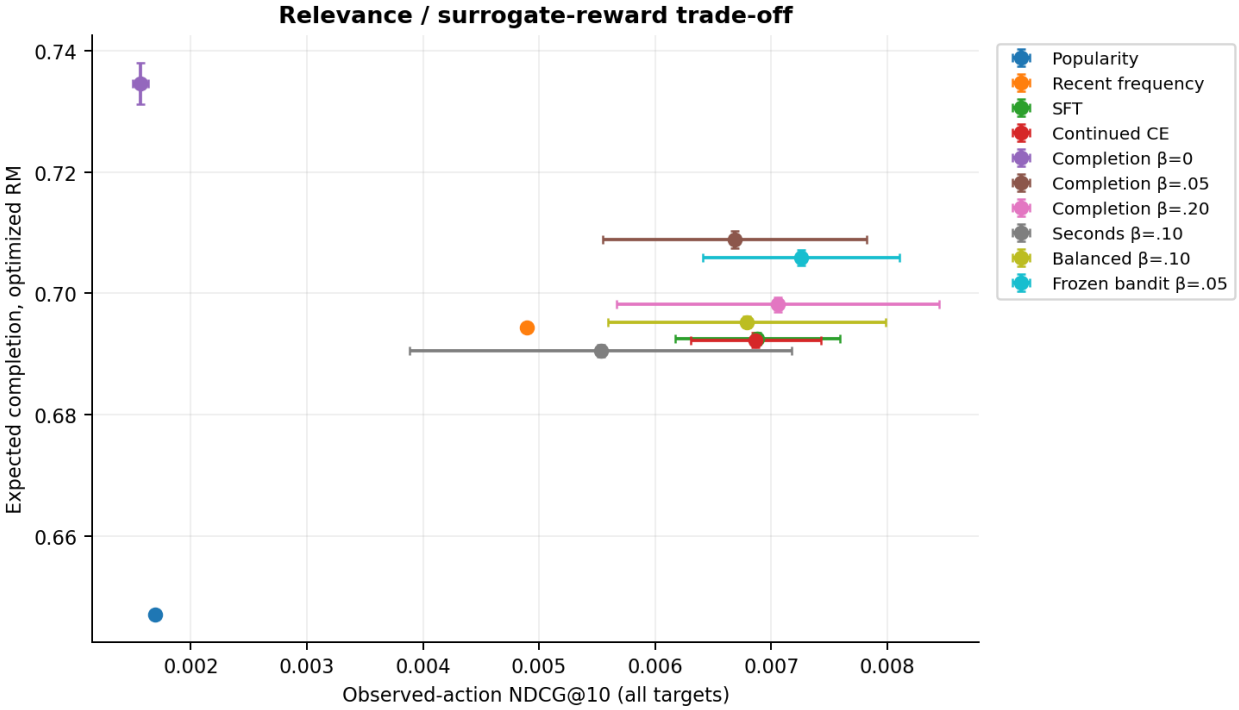


Рис. 4: Компромисс с surrogate reward; error bars — SD трёх seed, не 95% ДИ.

6 Как меняется поведение и есть ли коллапс

Без KL: entropy 7.336 → 4.987 nats; доля самого частого top-1 1.6% → 55.0%; вероятность уже знакомого трека 44.4% → 19.7%. Эти измерения показывают масштаб изменения распределения, но не объясняют причину сами по себе.

Ожидаемая длительность трека: SFT 188.3s, completion β=0 139.1s, seconds 204.1s. Длину рекомендуется рассматривать совместно с reward и релевантностью: выбор более длинного объекта сам по себе не означает большего времени реального прослушивания.

Вероятность выбрать трек без единого собственного train response label основной RM: SFT 7.9%, completion β=0 1.8%, balanced 7.8%. Такие треки известны GPT-2 и имеют метаданные,

но RM обобщает на них без item-specific откликов. Среднее |optimizer−auditor| на sampled actions: SFT 0.0842, β=0 0.0843.

Среди фактических test targets 63.2% уже встречались в полной предыдущей истории; среди known targets — 71.3%. Это свойство музыкальных логов объясняет, почему штраф за повторы может конфликтовать с matching-next-item NDCG. Оно не доказывает, что повторы полезны каждому пользователю или что разнообразие ухудшает удовлетворённость.

Coverage — доля словаря, появившаяся в top-10 хотя бы одного запроса. Exposure Gini — неравномерность top-10 показов по словарю. Top1 share — доля запросов с самым частым первым объектом. Cross-user Jaccard — сходство top-10 разных пользователей (первый из отобранных запросов пользователя; фиксированные случайные пары). Высокая concentration совместно со сходством выдач диагностирует обезличивание.

RM_std измеряет расхождение bootstrap-моделей, а optimizer/auditor gap — чувствительность к другому предиктору. Ни один показатель по отдельности не доказывает reward hacking. Для такого вывода нужны реальные outcomes на новых действиях либо рандомизированная онлайн-проверка. Контроль train-item-mean помогает увидеть, насколько RM превосходит простую популярностную оценку отклика.

В этом запуске вариант без KL смещается к более коротким трекам и общей выдаче для разных пользователей. Это частичный глобальный коллапс; вероятность повторить знакомый пользователю трек при этом снижается. Повтор знакомого объекта, повтор внутри сгенерированного списка и один общий объект у разных пользователей — разные явления. Balanced штрафует повторы только в последних 64 токенах, тогда как таблица P(repeat) использует всю прошлую историю.

Таблица 5: Как меняется поведение и есть ли коллапс

Модель	**Покрытие**	**Gini**	**Top1 share**	**Jaccard**	**Repeat P**
Популярность	0.1%	0.999	100.0%	1.000	14.2%
Частота в контексте	28.0%	0.878	1.8%	0.007	91.1%
SFT GPT-2	23.7%	0.898	1.6%	0.004	44.4%
Continued CE	22.7%	0.905	2.0%	0.004	43.5%
Completion, β=0	1.0%	0.998	55.0%	0.358	19.7%
Completion, β=.05	19.9%	0.922	1.8%	0.005	47.3%
Completion, β=.20	22.7%	0.904	1.5%	0.004	46.0%
Секунды, β=.10	22.9%	0.902	1.6%	0.003	42.0%
Balanced, β=.10	23.3%	0.899	1.4%	0.003	43.8%
Bandit, β=.05	21.0%	0.914	1.5%	0.004	49.0%

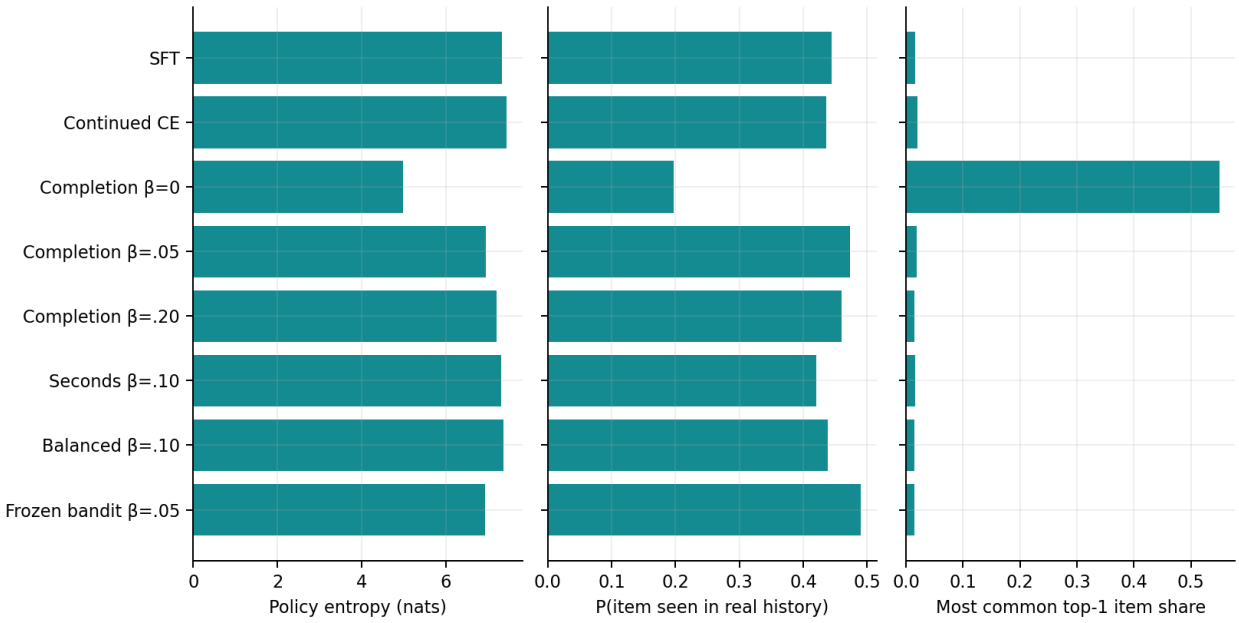


Рис. 5: Разные признаки коллапса измеряют разные свойства политики.

7 Пять шагов: рекомендация не равна действию

Диагностика использует 256 test-префиксов с пятью следующими одиночными неорганическими событиями и разрывами $\leq$30 минут. Это специальный срез непрерывных рекомендационных последовательностей; результаты не обобщаются на все сессии. Сравниваются: фактический префикс на каждом шаге; слепое добавление каждого top-1; неизменный префикс; принятие с вероятностью predicted completion.

Все четыре режима начинают с одного реального состояния. Политика в диагностике выбирает top-1, тогда как RL использовал stochastic sampling. В model-acceptance режиме общие uniforms; отклонённый ID не попадает в историю. Это эвристика перехода, а не обученная и проверенная модель принятия рекомендации: дослушивание и выбор объекта — разные события.

NDCG_anchor сравнивает выдачу с реально следующим logged item при разных искусственных контекстах. После первого шага это stress test согласованности с фактической траекторией, а не unbiased counterfactual relevance. Реальный пользователь при новой рекомендации мог выбрать другое действие или уйти; его последующие фактические действия нельзя считать outcomes новой политики.

KL к teacher-forced контексту измеряет накопившийся сдвиг распределения рекомендаций, same-top1 — долю совпадений первого объекта, within-list repeat — повтор среди уже предложенных объектов. RM на синтетических историях может становиться чрезмерно уверенной даже при ухудшении anchor relevance. Для реалистичного session return нужны отклик, organic transition, пропуски и stop/return model, а затем онлайн-валидация.

Наблюдаемый шаг 5 выбранной модели: append anchor NDCG 0.00210 против 0.00768 при actual prefix; KL=0.409. Greedy RM completion 0.6916 против actual-prefix 0.7710. Здесь в greedy режиме синтетический переход снижает и anchor matching, и RM score; рост награды на каждом шаге не наблюдается.

Таблица 6: Пять шагов: рекомендация не равна действию

Выбранная модель, шаг 5	**Anchor NDCG**	**RM top1**	**Audit top1**	**KL к actual**
append_all	0.00210	0.6916	0.7146	0.4092
frozen	0.00367	0.7714	0.7358	0.2679
model_acceptance	0.00232	0.6975	0.7176	0.3903
teacher_forced	0.00768	0.7710	0.7338	0.0000

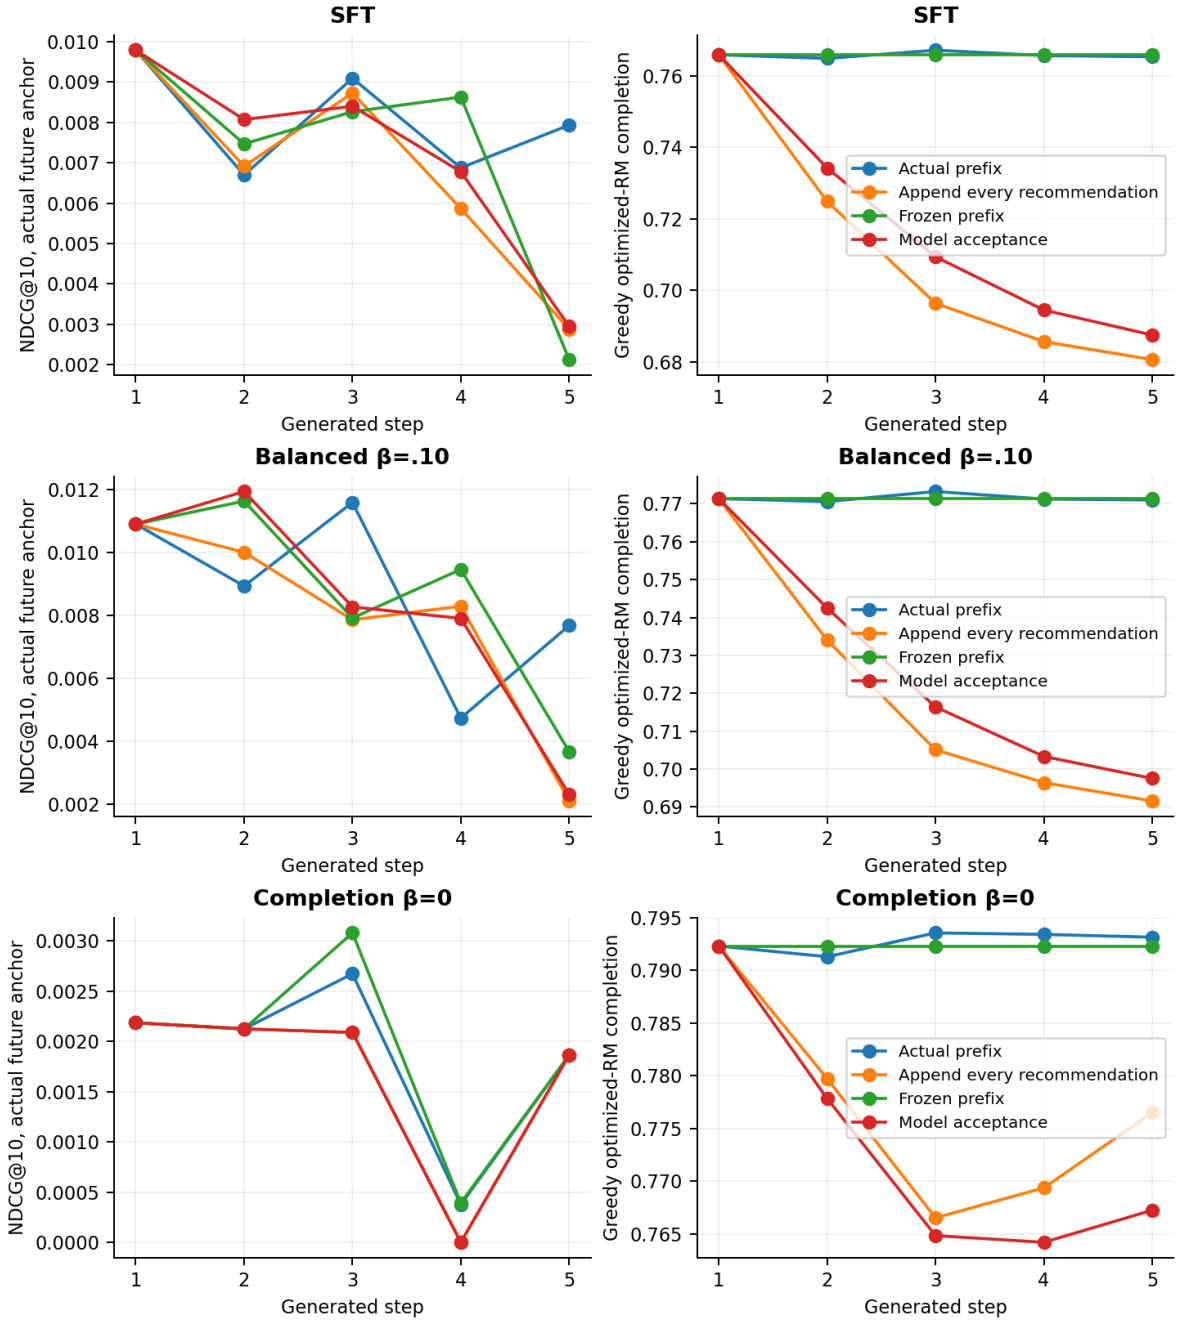


Рис. 6: Расхождение actual и synthetic префиксов. После шага 1 метрика по future anchor имеет только диагностический смысл.

7.1 Ожидаемая награда пяти stochastic шагов

Отдельная дополнительная диагностика соответствует sampling temperature 1 при обучении. Начальные 256 запросов случайно выбраны из общего test sample без отбора по будущему продолжению сессии. На запрос и seed — четыре траектории, пять шагов, $\gamma = 0.9$. В таблице нормированный return

$$\overline{G}_5 = \frac{\sum_{t=0}^{4} \gamma^t r_t}{\sum_{t=0}^{4} \gamma^t}; \tag{9}$$

это шкала среднего completion, а не суммарные реальные минуты.

Для append-среды первичная разность balanced − continued-CE: +0.00620 [+0.00502; +0.00750]. Интервал по пользователям условен на этих моделях и четырёх общих MC draws. Его нельзя переносить на реальное поведение пользователей.

Под одним и тем же фиксированным набором весов проверяются append и frozen переходы. Различия показывают чувствительность surrogate return к модели контекстного перехода. Это не причинное сравнение пользовательских сценариев; обе динамики искусственные. Predicted return proxy на пяти шагах относится к перекрывающимся будущим окнам, поэтому его сумму нельзя интерпретировать как пять независимых возвращений.

Эта диагностическая оценка была добавлена после начала validation запусков, до test metrics; выбор моделей не использует её результаты. Основной EXPERIMENT_PLAN.md сохранён, дополнение записано в DIAGNOSTIC_PLAN.md. Checkpoints выбирались по first-step validation utility, хотя training return имеет horizon 5 — дополнительное ограничение согласования train/selection objectives.

Таблица 7: Ожидаемая награда пяти stochastic шагов

Модель	Переход	G5 RM	G5 Audit	Repeat в списке
Continued CE	append	0.6976	0.6875	0.5%
Continued CE	frozen	0.6966	0.6872	0.3%
Balanced, β=.10	append	0.7038	0.6910	0.4%
Balanced, β=.10	frozen	0.6992	0.6886	0.4%
Completion, β=0	append	0.7744	0.7241	8.3%
Completion, β=0	frozen	0.7374	0.7009	6.6%
SFT GPT-2	append	0.6981	0.6878	0.4%
SFT GPT-2	frozen	0.6966	0.6874	0.4%

8 Долгосрочные цели: что доступно офлайн

Return proxy y=1, если после текущего действия наблюдалось любое listening event в интервале (t+24h,t+48h]. Окно не пересекает границу split. Вторая CatBoost-голова предсказывает этот label по прошлой истории и кандидату; balanced reward даёт ей вес .2. Это наблюдаемая будущая активность, а не вероятность причинного удержания от выбранного трека.

Для настоящей долгосрочной цели можно задавать discounted return: дослушивания + разнообразие/новизна + индикатор возвращения − риск ухода, либо обучать отдельную survival/stop модель с корректным censoring. Нужны активные дни, длина/завершение сессии, organic activity, skips и отрицательная обратная связь; желательно также экспозиции и propensities. В этой работе скачаны только listens, поэтому skips/likes не восстановлены.

Важное ограничение Yambda: исходный cohort выбран по активности в первых десяти месяцах и наличию действия в последнем. Наша равномерная подвыборка не устраняет этот survivorship bias. Высокая доля return labels не описывает churn всей аудитории. Окно 24–48h не означает отдельный вход в приложение и не измеряет удовлетворённость.

Офлайн можно проверить предиктивное качество proxy, временную устойчивость, поведение политики, чувствительность к reward и коллапс. Нельзя заключить, что изменение предсказанного return увеличило фактический retention. Нет истинных logging propensities или рандомизации: IS/DR, unbiased OPE и causal effect здесь не заявляются.

Онлайн-проверка: user-level randomized A/B, заранее зафиксированные eligible cohort и горизонты, primary D7/D14 return/active days, duration/completion как вторичные, guardrails на skips, однообразие и жалобы. Размер и длительность определяются по baseline rates и минимальному эффекту до запуска; в этой работе A/B не проводился.

В первичном сравнении Δ expected return-proxy = -0.00005 [-0.00018; +0.00005]. Интервал включает ноль: даже рост этого модельного proxy здесь не подтверждён. Это более узкий вывод, чем утверждение об отсутствии любого влияния на реальное удержание.

Таблица 8: Долгосрочные цели: что доступно офлайн

Return model	ROC-AUC	PR-AUC	Brier	Logloss	Observed rate
optimized_rm	0.6655	0.8779	0.1510	0.4750	79.9%
audit_rm	0.7325	0.9113	0.1469	0.4575	79.9%

9 Стоимость, надёжность и воспроизведение

Среда: Python 3.9.6, Torch 2.5.1, Transformers 4.53.2, CatBoost 1.2.10; CPU, 4 threads на процесс. SFT grid и три итоговых seed: 75.2 минут чистого fit. Reward model fits: 0.9 минут; суммарный fit дообучений 57.8 минут. Это сумма измеренных fit times, без скачивания/подготовки/всей оценки и не оценка FLOPs.

Для RL отдельно записаны 96 000 sampled actions/run, optimizer updates, время и число CE positive targets. Для continued-CE число labels меньше, чем число RL actions: одинаковое число обновлений не даёт равный computational budget. Отдельный baseline замороженной SFT позволяет оценить, добавило ли обычное дообучение пользу.

Часть fits выполнялась параллельно и конкурировала за CPU; это не изолированный hardware benchmark. Для RL seed 43/44 отключён idle busy-wait OpenMP (`OMP_WAIT_POLICY=PASSIVE`, `KMP_BLOCKTIME=0`), при тех же четырёх вычислительных threads; runtime_scheduling.json фиксирует различие. Суммарные fit times исключают прерванные инженерные прогоны и не равны всему времени разработки.

Аудит сравнил все 4,889,035 записей 1000 выбранных пользователей с исходным parquet, восстановил все 30,000 LM окон и проверил masking. Для всех cached states проверено history_max $<$ timestamp; по 256 примеров каждого split/kind точно восстановлены prefix, seen mask и labels. SHA источника и моделей проверены; saved test means пересчитаны из per-query CSV.

Восемь unit tests проверяют timestamp ties, causal replay и KV cache, masked labels, discount/leave-one-out baseline и направление градиента, OOV denominator, RM feature fractions и reward objectives. Tests не заменяют data audit. Упакованный архив содержит код, конфигурацию, планы, отчёт и компактные результаты; raw data, большие cache и обученные веса исключены.

Полное воспроизведение: создать Python 3.9+ environment, установить requirements.txt, выполнить make reproduce. Публичный parquet ~426 MB скачивается по закреплённой revision и проверяется SHA. Рекомендуется около 10 GB свободного диска и 16–32 GB RAM; этот запуск выполнен на машине с 32 GB. Точное время зависит от CPU и библиотек. Команда demo печатает top-10 реального heldout prefix после обучения.

Cache reuse проверяет config, source и model hashes; при изменении дизайна нужно новое output_dir. Текущие JSON содержат относительные пути внутри проекта. Reproduction сохраняет новый selection seal до test. Публикация или отправка работы не выполнялась.

10 Связь со статьями и ограничения

Petrov & Macdonald (2024), Aligning GPTRec with Beyond-Accuracy Goals with Reinforcement Learning: sequential Next-K и оптимизация свойств списка через RL; teacher-student pretraining и PPO. Здесь реализовано требуемое заданием next-item обучение GPT-2 и REINFORCE, поэтому это самостоятельный небольшой эксперимент по близкой идее, не буквальная репликация GPTRec. Источник: https://arxiv.org/abs/2403.04875

Matveev et al. (2026), Session-Level Optimization for Large-Scale Retrieval using REINFORCE with Multi-Step Off-Policy Correction: session rewards, feedback model и многошаговая коррекция off-policy обучения retrieval. Здесь нет их two-tower архитектуры, logged propensities или multi-step IS; actions сэмплируются on-policy в фиксированной surrogate среде. Авторы также различают model-based scores и реальные результаты. Источник: https://arxiv.org/abs/2607.02818

Описание Yambda и формулы времени: https://arxiv.org/abs/2505.22238 ; dataset card: https://huggingface.co/datasets/yandex/yambda . Pinned file URL и SHA находятся в data/SOURCE_MANIFEST.json. Код использует поля listens, is_organic, played_ratio_pct и track_length_seconds.

Ограничения: небольшая GPT-2 и ограниченные CPU budgets; 1000 пользователей и зависимые повторные события; словарь покрывает около половины test targets; arbitrary order внутри уже прошлых tied blocks; метаданные трактуются как стабильные; response модели оцениваются на логах другой политики; surrogate transitions и acceptance не валидированы; return proxy условен на активном исходном cohort; три seed и user-bootstrap не покрывают всю неопределённость.

Дизайн не был полностью слепым к составу holdout: до первого обучения словарь 2048 заменён на 16 384 после аудита train coverage/CPU benchmark; проверялось и покрытие heldout target IDs. Model metrics при этом не вычислялись. Пилот 2048 сохранился как data-only design audit и не используется для выбора лучшего результата. Все последующие model choices заданы в EXPERIMENT_PLAN.md и selection.lock.json.

Практический вывод следует из совместного рассмотрения релевантности, концентрации, двух reward estimators и устойчивости контекста. Рост surrogate reward достаточен для подтверждения работы оптимизатора, но недостаточен для заявления об улучшении пользовательского опыта. Следующий этап — более широкий item vocabulary, независимый временной/пользовательский cohort, richer feedback и онлайн-проверка.

11 Основные выводы

Оптимизатор способен менять поведение: completion без KL повышает ожидаемую RM награду с 0.6925 до 0.7346, но NDCG меняется с 0.00688 до 0.00157. Средняя длительность сокращается до 139.1s, самый частый top-1 занимает 55.0% запросов. Это полезный отрицательный результат: модельная награда и matching наблюдавшихся действий расходятся.

Balanced выбран до test и даёт небольшой прирост по основной и аудиторской RM. Первичный Δ NDCG -0.00008 [-0.00107; +0.00084]: точечная оценка близка к CE, но это не доказательство эквивалентности. Потеря 5% от CE соответствует -0.00034; интервал Δ шире этого масштаба. Для убедительной проверки допустимой потери нужны больше независимых пользователей/периодов и заранее рассчитанная мощность.

Более сильный KL сохраняет персонализацию ценой меньшего reward gain; seconds сдвигает длину объектов, а balanced меняет несколько целей одновременно. Frozen-bandit остаётся конкурентным описательным контролем: само добавление пяти сгенерированных ID не гарантирует пользы многошагового RL.

Долгосрочный proxy предсказуем лишь умеренно и не дал подтверждённого роста в первичном сравнении. Сдвиг пятишагового контекста заметен и зависит от decoding/transition assumptions. Следующий содержательный шаг — проверенная модель принятия/ухода, более широкий каталог и независимый cohort; вывод о реальном пользовательском эффекте требует онлайн-эксперимента.

Дополнительные таблицы

По каждому seed, все K и conditional metrics: artifacts/main/evaluation/test/summary.csv и summary.json. Парные интервалы: paired_comparisons.json. Все validation checkpoints и training diagnostics: curve_*.json. Пять шагов и все modes: evaluation/rollouts/summary.csv.

Таблица 9: Дополнительные таблицы

Модель	**NDCG@10 mean ± SD**	**Conditional NDCG@10**	**KL к SFT**
Популярность	0.00169 ± 0	0.00347	—
Частота в контексте	0.00490 ± 0	0.00965	—
SFT GPT-2	0.00688 ± 0.00071	0.01309	0.0000
Continued CE	0.00686 ± 0.00056	0.01296	0.0341
Completion, β=0	0.00157 ± 0.00007	0.00287	5.6628
Completion, β=.05	0.00669 ± 0.00113	0.01265	0.2479
Completion, β=.20	0.00706 ± 0.00139	0.01341	0.0266
Секунды, β=.10	0.00553 ± 0.00164	0.01060	0.1697
Balanced, β=.10	0.00679 ± 0.00120	0.01296	0.0369
Bandit, β=.05	0.00725 ± 0.00085	0.01391	0.1188